



Création et utilisation de la base de données

MK



Laplace Immo

Contexte du projet

Projet DATAImmo

- Collecte et organisation des transactions immobilières et foncières
- Meilleure prévision des prix
- Meilleur accompagnement



La stratégie de sauvegarde et la conformité RGPD

- Données publiques
- Eliminer les données personnelles
- Sauvegarde sur un serveur distant

Les données initiales

3 fichiers :

- Données ouvertes des Demandes de valeurs foncières
- Recensement de la population par commune (*INSEE*)
- Données publiques (*data.gouv*) sur les régions et les communes

Problématiques :

- Noms des acheteurs
- Données redondantes et/ou obsolètes
- Organisation des fichiers

L'extrait du dictionnaire des données

4 tables : **Bien** Commune Région Vente Lexique


DICTIONNAIRE DES DONNÉES - Bien

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
Id_bien	Identifiant du bien	Integer	NC	Elémentaire	PRIMARY KEY	
No_voie	Numéro dans la voie rues	Integer	NC	Elémentaire	Ne doit pas être nul	Données cadastrales
BTQ	Indice de répétition	Varchar	3	Elémentaire		Données cadastrales
Type_voie	Plusieurs valeurs (rue, avenue, chemin, etc.)	Varchar	4	Elémentaire	Ne doit pas être nul	Données cadastrales
Voie	Libellé de la voie	Varchar	50	Elémentaire	Ne doit pas être nul	Données cadastrales
Surface_carrez	Surface du bien en loi Carrez	Float	NC	Elémentaire	Ne doit pas être nul	Données cadastrales
Type_local	Maison, Appartement, dépendance (isolée), local industriel ou commercial et assimilés	Enum	50	Elémentaire	Ne doit pas être nul	Données cadastrales
Nombre_pieces		Integer	NC	Elémentaire	Ne doit pas être nul	Données cadastrales
Id_codedep_codecommune	Identifiant de la commune où se situe le bien	Integer	NC	Elémentaire	FOREIGN KEY	Données cadastrales

DICTIONNAIRE DES DONNÉES - Vente

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
Id_vente	Identifiant de l'acte de vente	Integer	NC	Elémentaire	PRIMARY KEY	
Id_bien	Identifiant du bien vendu	Integer	NC	Elémentaire	FOREIGN KEY	
Date_vente	Date de signature de l'acte	Date	10	Elémentaire	JJ/MM/AAAA	Document (acte)
Valeur	Montant déclaré de la vente (Prix net vendeur, TVA incluse, sans frais de notaires)	Float	NC	Elémentaire	Ne doit pas être nul	Document (acte)

Le schéma relationnel normalisé



La base de données avec les tables créées et les données chargées

▼	Bien	
	Id_bien	INTEGER
	No_voie	INTEGER
	BTQ	TEXT
	Type_voie	TEXT
	Voie	TEXT
	Surface_carrez	NUMERIC
	Type_local	TEXT
	Nombre_pieces	INTEGER
	Id_codedep_codecommune	TEXT
▼	Commune	
	Id_codedep_codecommune	TEXT
	Code_departement	TEXT
	Code_commune	TEXT
	Nom_commune	TEXT
	Id_region	INTEGER
	Population	INTEGER

▼	Region	
	Id_region	INTEGER
	Nom_region	TEXT
	Groupe_region	TEXT
▼	Vente	
	Id_vente	INTEGER
	Date_vente	TEXT
	Valeur	NUMERIC
	Id_bien	INTEGER

	Id_vente	Date_vente	Valeur	Id_bien
	Filtre	Filtre	Filtre	Filtre
1	1	2020/01/07	212150	1
2	2	2020/01/27	110600	2
3	3	2020/02/03	135700	3
4	4	2020/02/05	62500	4
5	5	2020/02/28	139130	5

Les requêtes ou screenshot qui permettent de démontrer le bon chargement des données

```
SELECT 'Bien' AS "name", 'table' AS "type", COUNT(*) AS "rows" FROM "Bien"  
UNION SELECT 'Commune' AS "name", 'table' AS "type", COUNT(*) AS "rows" FROM "Commune"  
UNION SELECT 'Region' AS "name", 'table' AS "type", COUNT(*) AS "rows" FROM "Region"  
UNION SELECT 'Vente' AS "name", 'table' AS "type", COUNT(*) AS "rows" FROM "Vente"
```

	name	type	rows
1	Bien	table	34154
2	Commune	table	34991
3	Region	table	19
4	Vente	table	34169



Requêtes SQL et résultats

Analyse des données

Requête 1

Nombre total d'appartements vendus au 1er semestre 2020

```
1  SELECT count(*) AS Total
2  FROM Vente AS v
3  INNER JOIN Bien As b ON v.Id_bien=b.Id_bien
4  WHERE b.Type_local='Appartement'
5  AND v.date BETWEEN '2020/01/01' AND '2020/06/30';
```

	Total
1	31378

Données : 34169 transactions uniques

Requête 2

Le nombre de ventes d'appartement par région pour le 1er semestre 2020

```
SELECT count(*) AS Nb_ventes, r. Nom_region
FROM Commune AS c
INNER JOIN Region AS r ON c.Id_region=r.Id_region
INNER JOIN Bien AS b ON b.Id_codedep_codecommune=c.Id_codedep_codecommune
INNER JOIN Vente AS v ON v.Id_bien=b.Id_bien
WHERE b.Type_local='Appartement'
AND v.Date_vente BETWEEN '2020/01/01' AND '2020/06/30'
GROUP BY r.Nom_region
ORDER BY Nb_ventes DESC
```

Données : 34169 transactions uniques

Requête 1 : 31378 appartements vendus

	Nb_ventes	Nom_region
1	13995	Ile-de-France
2	3649	Provence-Alpes-Côte d'Azur
3	3253	Auvergne-Rhône-Alpes
4	1932	Nouvelle-Aquitaine
5	1640	Occitanie
6	1357	Pays de la Loire
7	1254	Hauts-de-France
8	984	Grand Est
9	983	Bretagne
10	862	Normandie
11	696	Centre-Val de Loire
12	376	Bourgogne-Franche-Comté
13	223	Corse
14	94	Martinique
15	44	La Réunion
16	34	Guyane
17	2	Guadeloupe

Requête 3

Proportion des ventes d'appartements par le nombre de pièces

```
1 SELECT
2     b.Nombre_pieces,
3     count(*) AS Total_ventes,
4     ROUND(count(*) * 100.0 / SUM(COUNT(*)) OVER (), 2) AS Pourcentage
5 FROM Vente AS v
6 INNER JOIN Bien AS b ON v.Id_bien=b.Id_bien
7 WHERE b.Type_local='Appartement'
8 GROUP BY b.Nombre_pieces
```

	Nombre_pieces	Total_ventes	Pourcentage
1	0	30	0.1
2	1	6739	21.48
3	2	9783	31.18
4	3	8966	28.57
5	4	4460	14.21
6	5	1114	3.55
7	6	204	0.65
8	7	54	0.17
9	8	17	0.05
10	9	8	0.03
11	10	2	0.01
12	11	1	0.0

Requête 4

Liste des 10 départements où le prix du mètre carré est le plus élevé

```
1 SELECT c.Code_departement, floor(avg(v.Valeur/b.Surface_carrez)) AS Prix_moyen
2 FROM Commune AS c
3 INNER JOIN Bien AS b ON c.Id_codedep_codecommune=b.Id_codedep_codecommune
4 INNER JOIN Vente AS v ON b.Id_bien=v.Id_bien
5 GROUP BY c.Code_departement
6 ORDER BY Prix_moyen DESC
7 LIMIT 10
```

	Code_departement	Prix_moyen
1	75	12083.0
2	92	7300.0
3	94	5427.0
4	74	4780.0
5	06	4755.0
6	93	4385.0
7	78	4275.0
8	69	4099.0
9	2A	4062.0
10	33	3806.0

Requête 5

Prix moyen du mètre carré d'une maison en Île-de-France

```
1  SELECT floor(avg(v.Valeur/b.Surface_carrez)) AS Prix_moyen
2  FROM Region AS r
3  INNER JOIN Bien AS b ON c.Id_codedep_codecommune=b.Id_codedep_codecommune
4  INNER JOIN Vente AS v ON b.Id_bien=v.Id_bien
5  INNER JOIN Commune AS c ON r.Id_region=c.Id_region
6  WHERE r.Nom_region='Ile-de-France' AND b.Type_local='Maison'
```

Prix_moyen	
1	3764.0

Requête 6

Liste des 10 appartements les plus chers avec la région et le nombre de mètres carrés

```
1  SELECT
2      b.Id_bien,
3      round(v.Valeur,0) AS Prix,
4      r.Nom_region,
5      c.Code_departement,
6      round(b.Surface_carrez,0) AS Surface
7  FROM Bien AS b
8  JOIN Vente AS v ON b.Id_bien = v.Id_bien
9  JOIN Commune AS c on b.Id_codedep_codecommune = c.Id_codedep_codecommune
10 JOIN Region AS r on c.Id_region = r.Id_region
11 WHERE b.Type_local = 'Appartement'
12 ORDER BY Prix DESC
13 LIMIT 10;
```

	Id_bien	Prix	Nom_region	Code_departement	Surface
1	19402	9000000.0	Ile-de-France	75	9.0
2	26679	8600000.0	Ile-de-France	91	64.0
3	16937	8577713.0	Ile-de-France	75	20.0
4	19563	7620000.0	Ile-de-France	75	42.0
5	16834	7600000.0	Ile-de-France	75	253.0
6	16207	7535000.0	Ile-de-France	75	139.0
7	19065	7420000.0	Ile-de-France	75	360.0
8	19226	7200000.0	Ile-de-France	75	595.0
9	16176	7050000.0	Ile-de-France	75	122.0
10	16211	6600000.0	Ile-de-France	75	79.0

Requête 7

Taux d'évolution du nombre de ventes entre le premier et le second trimestre de 2020

```
1  WITH
2  VentesT1 AS (
3  SELECT count(*) AS Nbs_ventes_T1
4  FROM Vente AS v
5  WHERE v.Date_vente BETWEEN '2020/01/01' AND '2020/03/31'
6  ),
7  VentesT2 AS (
8  SELECT count(*) AS Nbs_ventes_T2
9  FROM Vente AS v
10 WHERE v.Date_vente BETWEEN '2020/04/01' AND '2020/06/30'
11 )
12
13 SELECT
14     Nbs_ventes_T1,
15     Nbs_ventes_T2,
16     round((1.0*(Nbs_ventes_T2-Nbs_ventes_T1)/Nbs_ventes_T1)*100,2) AS Taux_evolution
17 FROM VentesT1, VentesT2;
18
19
```

	Nbs_ventes_T1	Nbs_ventes_T2	Taux_evolution
1	16776	17393	3.68

Requête 8

Le classement des régions par rapport au prix au mètre carré des appartements de plus de 4 pièces

```
SELECT r.Nom_region, floor(avg(v.Valeur/b.Surface_carrez)) AS Prix_moyen_m2
FROM Region AS r
INNER JOIN Commune AS c ON c.Id_region=r.Id_region
INNER JOIN Bien AS b ON b.Id_codedep_codecommune=c.Id_codedep_codecommune
INNER JOIN Vente AS v ON v.Id_bien=b.Id_bien
WHERE b.Type_local='Appartement' AND b.Nombre_pieces>4
GROUP BY r.Nom_region
ORDER BY Prix_moyen_m2 DESC
```

	Nom_region	Prix_moyen_m2
1	Ile-de-France	8806.0
2	La Réunion	3659.0
3	Provence-Alpes-Côte d'Azur	3616.0
4	Corse	3117.0
5	Auvergne-Rhône-Alpes	2903.0
6	Nouvelle-Aquitaine	2476.0
7	Bretagne	2426.0

8	Pays de la Loire	2328.0
9	Hauts-de-France	2199.0
10	Occitanie	2106.0
11	Normandie	2025.0
12	Grand Est	1560.0
13	Centre-Val de Loire	1459.0
14	Bourgogne-Franche-Comté	1260.0
15	Martinique	574.0

Requête 9

Liste des communes ayant eu au moins 50 ventes au 1er trimestre

```
1  SELECT c.Nom_commune, count(*) AS Nb_ventes
2  FROM Commune AS c
3  INNER JOIN Bien AS b ON b.Id_codedep_codecommune=c.Id_codedep_codecommune
4  INNER JOIN Vente AS v ON v.Id_bien=b.Id_bien
5  WHERE v.Date_vente BETWEEN '2020/01/01' AND '2020/03/31'
6  GROUP BY c.Nom_commune
7  HAVING Nb_ventes > 50
8  ORDER BY Nb_ventes DESC
```

Requête 9

Liste des communes ayant eu au moins 50 ventes au 1er trimestre

	Nom_commune	Nb_ventes
1	Paris 17e Arrondissement	228
2	Paris 15e Arrondissement	215
3	Paris 18e Arrondissement	209
4	Nice	173
5	Paris 11e Arrondissement	169
6	Paris 16e Arrondissement	165
7	Bordeaux	157
8	Paris 14e Arrondissement	146
9	Paris 20e Arrondissement	127
10	Nantes	119
11	Paris 19e Arrondissement	116
12	Paris 12e Arrondissement	110
13	Paris 10e Arrondissement	109
14	Paris 9e Arrondissement	106
15	Grenoble	106
16	Boulogne-Billancourt	99
17	Paris 13e Arrondissement	94
18	Paris 7e Arrondissement	87
19	Paris 6e Arrondissement	86
20	Marseille 8e Arrondissement	81
21	Asnières-sur-Seine	81
22	Courbevoie	80
23	Paris 5e Arrondissement	79

	Nom_commune	Nb_ventes
24	Paris 3e Arrondissement	79
25	Toulouse	78
26	Antibes	77
27	Marseille 4e Arrondissement	72
28	Marseille 1er Arrondissement	71
29	Vincennes	68
30	Rueil-Malmaison	68
31	Lille	67
32	Marseille 9e Arrondissement	66
33	Montreuil	65
34	Angers	64
35	Nîmes	63
36	Sète	62
37	Paris 8e Arrondissement	62
38	La Ciotat	62
39	Rennes	61
40	Paris 2e Arrondissement	61
41	Paris 4e Arrondissement	60
42	Toulon	59
43	Levallois-Perret	59
44	Saint-Maur-des-Fossés	56
45	Versailles	54
46	Ajaccio	54

Requête 10

Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces

```
1  WITH
2  Appt2P AS (
3    SELECT round(avg(v.Valeur/b.Surface_carrez),2) AS Prix_2pieces
4    FROM Vente AS v
5    JOIN Bien AS b ON b.Id_bien=v.Id_bien
6    WHERE b.Nombre_pieces=2 AND b.Type_local='Appartement'
7  ),
8  Appt3P AS (
9    SELECT round(avg(v.Valeur/b.Surface_carrez),2) AS Prix_3pieces
10   FROM Vente AS v
11   JOIN Bien AS b ON b.Id_bien=v.Id_bien
12   WHERE b.Nombre_pieces=3 AND b.Type_local='Appartement'
13  )
14
15  SELECT
16    Prix_2pieces,
17    Prix_3pieces,
18    round(((Prix_3pieces-Prix_2pieces)/Prix_2pieces)*100,2) AS Difference_pourcentage
19  FROM Appt2P, Appt3P;
```

	Prix_2pieces	Prix_3pieces	Difference_pourcentage
1	4964.87	4335.13	-12.68

Requête 11

Les moyennes de valeurs foncières pour le top 3 des communes des départements 6, 13, 33, 59 et 69

```
WITH Valeurs AS (  
  SELECT  
    c.code_departement,  
    c.Nom_commune,  
    round(avg(v.Valeur),0) AS Valeur_fonciere_moyenne,  
    row_number() OVER (  
      PARTITION BY c.Code_departement  
      ORDER BY round(avg(v.Valeur),0) DESC  
    ) AS rang  
  FROM Commune AS c  
  JOIN Bien AS b ON b.Id_codedep_codecommune=c.Id_codedep_codecommune  
  JOIN Vente AS v ON b.Id_bien=v.Id_bien  
  WHERE c.Code_departement IN ('06','13','33','59','69')  
  GROUP BY c.Code_departement, c.Nom_commune  
)  
  
SELECT *  
FROM Valeurs  
WHERE rang <=3  
ORDER BY Code_departement, rang
```

	code_departement	Nom_commune	Valeur_fonciere_moyenne	rang
1	06	Saint-Jean-Cap-Ferrat	968750.0	1
2	06	Eze	655000.0	2
3	06	Mouans-Sartoux	476898.0	3
4	13	Gignac-la-Nerthe	330000.0	1
5	13	Saint-Savournin	314425.0	2
6	13	Cassis	313417.0	3
7	33	Lège-Cap-Ferret	549501.0	1
8	33	Vayres	335000.0	2
9	33	Arcachon	307436.0	3
10	59	Bersée	433202.0	1
11	59	Cysoing	408550.0	2
12	59	Halluin	322250.0	3
13	69	Ville-sur-Jarnioux	485300.0	1
14	69	Lyon 2e Arrondissement	455217.0	2
15	69	Lyon 6e Arrondissement	426968.0	3

Requête 12

Les 20 communes avec le plus de transactions pour 1000 habitants
pour les communes qui dépassent les 10 000 habitants

```
SELECT
    c.Nom_commune,
    round(count(*) / (round(c.Population)/1000),2) AS Nb_ventes_pour_mille
FROM Vente AS v
JOIN Bien AS b ON v.Id_bien=b.Id_bien
JOIN Commune AS c ON b.Id_codedep_codecommune=c.Id_codedep_codecommune
WHERE c.Population > 10000
GROUP BY c.Nom_commune
ORDER BY Nb_ventes_pour_mille DESC
LIMIT 20
```

	Nom_commune	Nb_ventes_pour_mille
1	Paris 2e Arrondissement	5.84
2	Paris 1er Arrondissement	4.92
3	Paris 3e Arrondissement	4.69
4	Arcachon	4.62
5	La Baule-Escoublac	4.58
6	Paris 4e Arrondissement	4.08
7	Roquebrune-Cap-Martin	3.99
8	Paris 8e Arrondissement	3.83
9	Sanary-sur-Mer	3.5
10	Paris 9e Arrondissement	3.43

11	La Londe-les-Maures	3.43
12	Paris 6e Arrondissement	3.38
13	Saint-Cyr-sur-Mer	3.24
14	Chantilly	3.13
15	Saint-Mandé	3.06
16	Pornichet	3.06
17	Paris 10e Arrondissement	3.04
18	Menton	2.94
19	Saint-Hilaire-de-Riez	2.87
20	Vincennes	2.81



Merci !